

# Chapter7支持向量机1Support Vector Machine (SVM)

1. 线性支持向量机
2. 核支持向量机
3. 序列最小优化算法

## 超平面选择

1. 超平面选择：best hyperplane是最大化两个类别边距的那种方式；超平面对每个类别最近的元素最远




### SVM和logistic回归的区别

SVM更关心的是靠近中间分割线的点，让他们尽可能地远离中间线，而不是在所有点上达到最优，因为那样的话，要使得一部分点靠近中间线来换取另外一部分点更加远离中间线。

因此支持向量机和和逻辑斯蒂回归的不同点，一个是考虑局部（不关心已经确定远离的点，更考虑靠近中间分割线的点），一个是考虑全局（已经远离的点可能通过调整中间线使其能够更加远离）

## 2. 间隔Margin

点到分离超平面的距离反映了预测的置信度



## 二分类问题

### 线性分类器

■ 样本  $(\mathbf{x}, y), y \in \{-1, 1\}$

■ 线性分类器:

$$f_{\mathbf{w}, b}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x} + b)$$

$$g(z) = \begin{cases} 1, & \text{如果 } z \geq 0 \\ -1, & \text{如果 } z < 0 \end{cases}$$

■ 超平面:  $\mathbf{w}^T \mathbf{x} + b = 0$  .

### 函数间隔(Functional Margin)

■ 对于一个训练样本  $(\mathbf{x}^i, y^i)$ ，它到  $(\mathbf{w}, b)$  确定的超平面的函数间隔为：

$$\hat{\gamma}^i = y^i(\mathbf{w}^T \mathbf{x}^i + b)$$

- $y^i = 1$ ， $\mathbf{w}^T \mathbf{x}^i + b$  是一个大的正数.
- $y^i = -1$ ， $\mathbf{w}^T \mathbf{x}^i + b$  是一个比较小的负数.
- $y^i(\mathbf{w}^T \mathbf{x}^i + b) > 0$ ，模型对样本的预测是正确的.

• 大的函数间隔  $\rightarrow$  确信正确的预测

■ 对于训练数据集  $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$ ，它的函数间隔定义为所有样本中最小的那个

$$\hat{\gamma} = \min_i \hat{\gamma}^i, i = 1, 2, \dots, N$$

### 几何间隔(Geometric Margin)


■ 点B:  $\mathbf{x}^i - \gamma^i \mathbf{w} / \|\mathbf{w}\|_2$

■ 点B在决策边界上:

$$\mathbf{w}^T (\mathbf{x}^i - \gamma^i \mathbf{w} / \|\mathbf{w}\|_2) + b = 0$$

■ 求解方程可得  $\gamma^i$  :

$$\gamma^i = \frac{\mathbf{w}^T \mathbf{x}^i + b}{\|\mathbf{w}\|_2} = \left( \frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2}$$



■ 样本  $(\mathbf{x}^i, y^i)$  的几何间隔为:

$$\gamma^i = y^i \left( \left( \frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2} \right)$$

■训练数据集  $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$  关于判别界面  
(参数为 $(\mathbf{w}, b)$ ) 的几何间隔:


$$\gamma = \min_i \gamma^i, i = 1, 2, \dots, N$$

■函数间隔与几何间隔的关系:

$$\gamma^i = \frac{\hat{\gamma}^i}{\|\mathbf{w}\|_2}, \quad \gamma = \frac{\hat{\gamma}}{\|\mathbf{w}\|_2}.$$

•如果  $\|\mathbf{w}\|_2 = 1$  , 二者相等。

■几何间隔具有不变性。



因为函数间隔是我们定义的，在定义的时候就有几何间隔的色彩。几何间隔最大的优势就是不管将 $\mathbf{w}$ 和 $b$ 扩大几倍，几何间隔都没有影响。

## 最优间隔分类器

给定一个训练集，一个自然的想法是试图找到一个使几何间隔最大化的决策边界，这表示对训练集的有可信的预测并且对训练数据的良好“拟合”。

间隔最大化

$$\begin{aligned} & \max_{\gamma, \mathbf{w}, b} \gamma \\ & s.t. \quad y^i \left( \left( \frac{\mathbf{w}}{\|\mathbf{w}\|_2} \right)^T \mathbf{x}^i + \frac{b}{\|\mathbf{w}\|_2} \right) \geq \gamma, i = 1, \dots, N \end{aligned}$$

将问题转换为

$$\begin{aligned} \max_{\gamma, \mathbf{w}, b} \quad & \frac{\hat{\gamma}}{\|\mathbf{w}\|_2} \\ \text{s.t.} \quad & y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq \hat{\gamma}, i = 1, \dots, N \end{aligned}$$

给定  $\hat{\gamma} = 1$  简化问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} \quad & y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1, i = 1, \dots, N \end{aligned}$$

求解：使用二次规划(QP)方法求解

二次规划(QP, Quadratic Programming)定义:目标函数为二次函数，约束条件为线性约束，属于最简单的一种非线性规划。

## 线性SVM

### 基本定义

#### 1. 基本定义

- 输入：线性可分的训练数据集  $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$
- 输出：判别函数及决策/判别界面

通过求解如下最优化问题来得到最优分类器的参数  $(\mathbf{w}^*, b)$

- $$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$s.t. \quad y^i (\mathbf{w}^T \mathbf{x}^i + b) \geq 1, i = 1, \dots, N$$

• 分离超平面:  $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$

• 判别函数:  $f_{\mathbf{w}, b}(\mathbf{x}) = \text{sign}((\mathbf{w}^*)^T \mathbf{x} + b^*)$

理论支持：对于线性可分的训练数据集，最大间隔分类器存在且唯一。

## 2. 支持向量和间隔


■ **支持向量**：距分离超平面最近的训练样本。

$$y(\mathbf{w}^T \mathbf{x} + b) = 1$$

■ 函数间隔:  $\hat{\gamma} = 1$

■ 几何间隔:  $\gamma = \frac{1}{\|\mathbf{w}\|_2}$

■ 间隔:  $\frac{2}{\|\mathbf{w}\|_2}$



## 拉格朗日对偶→求解

原始的最优化问题：

$$\min_x \quad f_0(x)$$

$$s.t. \quad f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$h_j(x) = 0, j = 1, 2, \dots, p$$



原始问题通常会带有很多约束条件，这样直接求解原始问题往往是很困难的，于是考虑将原始问题转化为它的对偶问题，通过求解它的对偶问题来得到原始问题的解。**对偶性（Duality）**是凸优化问题的核心内容。

将原始问题的拉格朗日函数定义为：

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p v_j h_j(x)$$

其中  $x \in R^n, \lambda \in R^m, v \in R^p$ 。



拉格朗日函数L可以看成关于x的函数，它实际上是对原始问题中目标函数与约束条件进行线性加权。目标函数的权系数是1，约束条件的权系数是  $\lambda_i$  或  $v_i$ 。若将L看成关于  $\lambda_i, v_i$  的函数，则其余部分可以看成常数，L为一个关于  $\lambda_i$  和  $v_i$  仿射函数。



<https://blog.csdn.net/frotime/article/details/90291392>

- 简单情形

## ■等式约束的最优化问题:

$$\begin{aligned} \min_{\mathbf{w}} f(\mathbf{w}) \\ \text{s.t. } h_i(\mathbf{w}) = 0, i = 1, \dots, l \end{aligned}$$

•拉格朗日函数：

$$L(\mathbf{w}, \boldsymbol{\beta}) = f(\mathbf{w}) + \sum_{i=1}^l \beta_i h_i(\mathbf{w})$$

拉格朗日乘子

## ■求解：偏导数为0

$$\frac{\partial L}{\partial w_i} = 0, \quad \frac{\partial L}{\partial \beta_i} = 0$$

- 一般情形

基本定义

## ■约束条件中含有等式及不等式约束时:

$$\begin{aligned} \min_{\mathbf{w}} f(\mathbf{w}) \\ \text{s.t. } g_i(\mathbf{w}) \leq 0, i = 1, \dots, k \\ h_i(\mathbf{w}) = 0, i = 1, \dots, l \end{aligned}$$

原问题  
Primary Problem

## ■广义拉格朗日函数:

$$L(\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{w}) + \sum_{i=1}^k \alpha_i g_i(\mathbf{w}) + \sum_{i=1}^l \beta_i h_i(\mathbf{w})$$

非负

拉格朗日乘子

原始问题定义：Primitive Problem  $\rightarrow \theta_p$

## ■定义如下最优化问题:

$$\theta_p(\mathbf{w}) = \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} L(\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$



■如果满足所有约束条件:

$$\theta_p(\mathbf{w}) = f(\mathbf{w})$$

■分析下面的最优化问题:

$$\min_{\mathbf{w}} f(\mathbf{w}) = \min_{\mathbf{w}} \theta_p(\mathbf{w}) = \min_{\mathbf{w}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{w}, \alpha, \beta)$$

■原始问题 (Primitive problem) :

$$\begin{aligned} \min_{\mathbf{w}} f(\mathbf{w}) \\ \text{s.t. } g_i(\mathbf{w}) \leq 0, i = 1, \dots, k \\ h_i(\mathbf{w}) = 0, i = 1, \dots, l \end{aligned}$$

■定义该问题的最优值 :

$$p^* = \min_{\mathbf{w}} \theta_p(\mathbf{w}) \quad \text{原问题的最优值}$$

$$p^* = \min_w \theta_p(w)$$

对偶问题定义 : Dual Problem

■对偶问题 (Dual problem) :

$$\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{w}} L(\mathbf{w}, \alpha, \beta)$$

$$\theta_D(\alpha, \beta) = \min_{\mathbf{w}} L(\mathbf{w}, \alpha, \beta)$$

■对偶问题的最优值:

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta)$$

■原问题与对偶问题 :

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{w}} L(\mathbf{w}, \alpha, \beta) \leq \min_{\mathbf{w}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{w}, \alpha, \beta) = p^*$$

Dual Problem & Primitive Problem

$$d^* = \max_{\alpha, \beta; \alpha_i \geq 0} \min_w L(w, \alpha, \beta) \leq \min_w \max_{\alpha, \beta; \alpha_i \geq 0} L(w, \alpha, \beta) = p^*$$

那么什么情况下可以找到  $d^* = p^*$ ，即满足强对偶  $\rightarrow$  KKT 条件

■ 如果原问题是凸优化问题，且存在严格满足约束条件的  $w$ 。

$$\min_w f(w)$$

$$s.t. \ g_i(w) \leq 0, \ i = 1, \dots, k$$

$$h_i(w) = 0, \ i = 1, \dots, l$$

$f(\cdot)$ 、 $g_i(\cdot)$  是凸函数， $h_i(\cdot)$  是仿射函数 affine function

■ 则存在  $w^*, \alpha^*, \beta^*$ ，使得  $w^*$  是原问题的解， $\alpha^*, \beta^*$  是对偶问题的解，且满足：

$$p^* = d^* = L(w^*, \alpha^*, \beta^*)$$

■  $w^*, \alpha^*, \beta^*$  满足 Karush-Kuhn-Tucker (KKT) 条件：

$$\frac{\partial}{\partial w_i} L(w^*, \alpha^*, \beta^*) = 0, \ i = 1, 2, \dots, M$$

$$g_i(w^*) \leq 0, \ i = 1, \dots, k$$

$$h_i(w^*) = 0, \ i = 1, \dots, l$$

$$\alpha_i^* g_i(w^*) = 0, \ i = 1, \dots, k$$

$$\alpha_i^* \geq 0, \ i = 1, \dots, k$$


KKT 对偶互补性

最优间隔分类器：对偶解

■ 最优间隔分类器——原问题：

$$\min_{w, b} \frac{1}{2} \|w\|_2^2$$

$$s.t. \ y^i (w^T x^i + b) \geq 1, \ i = 1, \dots, N$$



■ 约束条件：

$$g_i(w) = -y^i (w^T x^i + b) + 1 \leq 0, \ i = 1, \dots, N$$

■ KKT对偶互补条件： $\alpha_i^* g_i(w^*) = 0, \ i = 1, \dots, k$

$$g_i(w^*) < 0 \Rightarrow \alpha_i^* = 0$$

$$\alpha_i^* \neq 0 \Rightarrow g_i(w^*) = 0$$

支持向量

■ 支持向量的数量远小于训练样本的数目！



**支持向量**（Support Vectors）是那些对决策边界起关键作用的训练样本。这些样本在训练过程中定义了分类超平面的位置，而**其他样本**则不会直接影响决策边界的选择。

因此，支持向量数量远小于训练样本数目。

## 对偶解

### ■拉格朗日函数:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_{i=1}^N \alpha_i \left[ y^i (\mathbf{w}^T \mathbf{x}^i + b) - 1 \right]$$

### ■对偶解:

- 固定  $\alpha$  , 关于参数  $\mathbf{w}$  和  $b$  最小化  $L(\mathbf{w}, b, \alpha)$  得到  $\theta_D(\alpha)$

$$\theta_D(\alpha) = \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$$

- 最大化  $\theta_D(\alpha)$  得到对偶问题的最优值  $d^*$

■ 固定  $\alpha$  , 关于参数  $w$  和  $b$  最小化  $L(w, b, \alpha)$  得到  $\theta_D(\alpha)$

• 求解  $w$  和  $b$  
$$L(w, b, \alpha) = \frac{1}{2} \|w\|_2^2 - \sum_{i=1}^N \alpha_i [y^i (w^T x^i + b) - 1]$$

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y^i x^i = 0,$$



$$w = \sum_{i=1}^N \alpha_i y^i x^i$$

$$\frac{\partial}{\partial b} L(w, b, \alpha) = \sum_{i=1}^N \alpha_i y^i = 0,$$

• 代入拉格朗日函数

$$\theta_D(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (x^i)^T x^j.$$

## ■ 对偶问题

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (x^i)^T x^j \\ \text{s.t.} \quad & \alpha_i \geq 0, i = 1, \dots, N, \\ & \sum_{i=1}^N \alpha_i y^i = 0. \end{aligned}$$

对偶解推导

下一步求解

■ 输入：线性可分的训练数据集  $S = \{(\mathbf{x}^i, y^i), i=1, \dots, N\}$

■ 输出：分离超平面和判别函数。

• 通过求解对偶问题来得到最优解  $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j \\ \text{s.t.} \quad & \alpha_i \geq 0, i=1, \dots, N, \\ & \sum_{i=1}^N \alpha_i y^i = 0. \end{aligned}$$

• 得到原问题的最优解  $(\mathbf{w}^*, b^*)$

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i, \quad b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j. \quad \alpha_j^* > 0$$

• 分离超平面:  $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$  , 判别函数:  $f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^*$ .

其中，需要注意的：使用支持向量进行计算

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i, \quad b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j. \quad \alpha_j^* > 0$$

■ 计算 $\mathbf{w}^*$ 时 $b^*$ ，只需要利用 $\alpha_i^* > 0$ 的那些样本(支持向量)来计算。

$$f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^* = \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x} + b^*$$

■ 预测时是否需要所有的训练样本来计算？

■ 对偶形式：只需计算训练样本与输入特征的内积。

■ 核技巧!

$$(\mathbf{x}^i)^T \mathbf{x} = \langle \mathbf{x}^i, \mathbf{x} \rangle$$

## 软间隔Soft Margin分类器

解决训练数据线性不可分的情况

- 允许一些样本（离群点或噪声样本）违反原来的不等式约束条件： $y^i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1$ ，但是数目要少。

## ■ 目标函数：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N I_{y^i(\mathbf{w}^T \mathbf{x}^i + b) < 1}$$

## ■ 不易求解！

## ■ 替代损失：

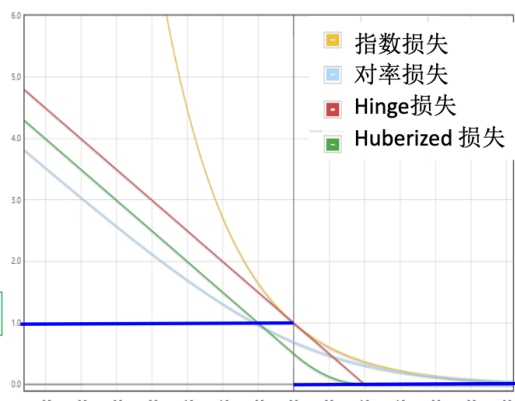
0/1损失

hinge损失:  $l_{\text{hinge}}(z) = \max(0, 1 - z)$

指数损失:  $l_{\text{exp}}(z) = \exp(-z)$

Huberized损失:  $l_{\text{hub}}(z) = 0.5 - z, z < 0; 0.5(1 - z)^2, 0 \leq z \leq 1; 0, z > 1$

对率损失(logistic):  $l_{\text{log}}(z) = \log(1 + \exp(-z))$



## 1. Hinge损失

## ■ Hinge 损失：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \max\{0, 1 - y^i(\mathbf{w}^T \mathbf{x}^i + b)\}$$

## ■ 松弛变量 $\xi_i$ ：


$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } y^i(\mathbf{w}^T \mathbf{x}^i + b) \geq 1 - \xi_i, \quad i = 1, \dots, N,$$

$$\xi_i \geq 0, \quad i = 1, \dots, N.$$

## ■ 软间隔分类器.

## ■ 凸二次规划问题。





为了描述这些错误，我们引入了松弛变量  $\xi_i$  来表示第  $i$  个样本违反间隔的程度，并引入一个损失函数来量化这些错误。

目标是**最小化间隔最大化和分类错误之间的折中**。

■拉格朗日函数 
$$L(w, b, \xi, a, \eta) = \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [y^i (w^T x^i + b) - 1 + \xi_i] - \sum_{i=1}^N \eta_i \xi_i.$$

■固定  $a, \eta$ ，关于参数  $w, b$  和  $\xi$ ，最小化  $L(w, b, \xi, a, \eta)$ ，得到  $\theta_D(a, \eta)$

$$\theta_D(a, \eta) = \min_{w, b, \xi} L(w, b, \xi, a, \eta) \quad \left\{ \begin{array}{l} \nabla_w L(w, b, \xi, a, \eta) = w - \sum_{i=1}^N \alpha_i y^i x^i = 0, \Rightarrow w = \sum_{i=1}^N \alpha_i y^i x^i \\ \frac{\partial}{\partial b} L(w, b, \xi, a, \eta) = \sum_{i=1}^N \alpha_i y^i = 0, \\ \frac{\partial}{\partial \xi_i} L(w, b, \xi, a, \eta) = C - \alpha_i - \eta_i = 0. \end{array} \right.$$

$$\theta_D(a) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (x^i)^T x^j.$$

■最大化  $\theta_D(a, \eta)$ ，得到最优值  $d^*$ 。

■对偶问题 
$$\max_a \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (x^i)^T x^j$$
  

$$s.t. \ 0 \leq \alpha_i \leq C, i=1, \dots, N,$$
  

$$\sum_{i=1}^N \alpha_i y^i = 0.$$

■ 输入：训练数据集  $S = \{(\mathbf{x}^i, y^i), i = 1, \dots, N\}$

■ 输出：分类超平面与分类决策函数.

• 选择参数  $C$  , 并求解对偶问题, 得最优解  $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)$

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N y^i y^j \alpha_i \alpha_j (\mathbf{x}^i)^T \mathbf{x}^j$$

$$s.t. \ 0 \leq \alpha_i \leq C, i = 1, \dots, N,$$

$$\sum_{i=1}^N \alpha_i y^i = 0.$$

• 求解最优的  $(\mathbf{w}^*, b^*)$  :  $\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^i \mathbf{x}^i$ ,  $b^* = y^j - \sum_{i=1}^N \alpha_i^* y^i (\mathbf{x}^i)^T \mathbf{x}^j$ .  $0 < \alpha_j^* < C$

• 分类超平面:  $(\mathbf{w}^*)^T \mathbf{x} + b^* = 0$  , 判别函数:  $f_{\mathbf{w},b}(\mathbf{x}) = (\mathbf{w}^*)^T \mathbf{x} + b^*$ .



Different between the hinge and the Lagrange

Lagrange:  $0 < \alpha_j^*$

Hinge:  $0 < \alpha_j^* < C$

## 非线性SVM

### 支持向量



■ 支持向量:  $\alpha_i^* > 0$

■ KKT对偶互补条件:  $\alpha_i^* g_i(\mathbf{w}^*) = 0$   $\eta_i^* \xi_i = 0$ .  $\frac{\partial}{\partial \xi_i} L(\mathbf{w}, b, \xi, \mathbf{a}, \eta) = C - \alpha_i - \eta_i = 0$ .

$$\alpha_i^* \left[ y^i \left( (\mathbf{w}^*)^T \mathbf{x}^i + b \right) - 1 + \xi_i \right] = 0, \quad \eta_i^* \xi_i = 0.$$

■ 如果  $\alpha_i^* = 0$  ,  $y^i \left( (\mathbf{w}^*)^T \mathbf{x}^i + b \right) \geq 1$

■ 如果  $0 < \alpha_i^* < C$  ,  $y^i \left( (\mathbf{w}^*)^T \mathbf{x}^i + b \right) = 1$

■ 如果  $\alpha_i^* = C$  ,  $y^i \left( (\mathbf{w}^*)^T \mathbf{x}^i + b \right) \leq 1$

- $0 < \xi_i < 1$
- $\xi_i = 1$
- $\xi_i > 1$

